



Proyecto Final Data Mining

Propósito formativo. El objetivo del proyecto es que el estudiante entienda con precisión **por qué** aplica cada técnica, **cómo** interpretar los resultados y **cómo** argumentar (con sustento) los *insights* encontrados. No basta con ejecutar procedimientos: se evalúa la **interpretación** y la **justificación** de decisiones.

Criterio de calidad. Toda decisión técnica (p.ej., imputación, tratamiento de outliers, elección de pruebas, selección de variables, métricas y visualizaciones) debe estar respaldada por:

- evidencia empírica (tablas, gráficas, pruebas, métricas comparativas), y
- referencias (criterios vistos en clase + literatura/documentación/artículos/libros confiables).

Entregables obligatorios (4). El proyecto se entrega en cuatro piezas complementarias:

1. **Cuaderno (Notebook) reproducible:** ejecuta el flujo completo e incluye narrativa clara (*qué se hizo, por qué y qué significa*).
2. **Documento de soporte de decisiones (PDF):** explica **qué respalda cada decisión** (criterios, supuestos, riesgos, comparaciones y referencias).
3. **Presentación:** síntesis ejecutiva de objetivos, hallazgos, decisiones clave, limitaciones y recomendaciones.
4. **Dashboard:** tablero interactivo que resuma resultados y permita explorar hallazgos con filtros/segmentación.

Nota. Se valorará especialmente la claridad conceptual, la lectura crítica de resultados y la trazabilidad de decisiones con evidencia y referencias.

1. Descripción general

El proyecto consiste en seleccionar un problema real (negocio, ciencia, industria o sociedad), justificarlo con datos y desarrollar un análisis riguroso con técnicas de Data Mining.

Enfoque obligatorio (mínimo):

- Definición del problema, alcance y objetivos.
- EDA (univariado, bivariado y calidad de datos).
- Tratamiento de valores faltantes e imputación.
- Detección y manejo de atípicos (outliers).
- Selección preliminar de variables (redundancia/multicolinealidad).

Enfoque opcional (recomendado):

- Modelado (clasificación/regresión/segmentación) + evaluación.
- Interpretabilidad (importancias, SHAP, análisis de errores).

2. Equipos, dataset y reglas de reproducibilidad

2.1. Equipos

- Tamaño sugerido: 3–4 estudiantes (o individual con autorización).
- Se debe evidenciar el aporte de cada integrante (commits, bitácora, secciones del documento).

2.2. Dataset

Requisitos mínimos:

- Idealmente $\geq 1,000$ filas y ≥ 8 variables (mezcla de tipos cuando aplique).
- Debe existir una pregunta clara: **(i)** con variable objetivo, o **(ii)** de análisis descriptivo/segmentación.
- Fuente documentada (URL, repositorio o descripción verificable del origen) y fecha de obtención.

Prohibiciones:

- Datos personales sensibles sin anonimización o sin permiso.
- Entregas sin trazabilidad (sin código ejecutable o sin flujo replicable).

2.3. Reproducibilidad (obligatoria)

- Entregar un repositorio con:
 - README (cómo ejecutar, estructura, dependencias, decisiones de diseño).
 - `requirements.txt` o `environment.yml`.
 - Notebook(s) o scripts con ejecución de extremo a extremo.
 - Carpeta `data/` o enlace estable a datos.
- Los resultados clave deben poder recrearse (tablas/figuras principales).

3. Entregables y formato

3.1. Entregable 1: Cuaderno (Notebook) reproducible

Debe contener:

1. Carga y descripción inicial del dataset.
2. EDA univariado y bivariado con interpretación (no solo gráficas).
3. Diagnóstico de faltantes + imputación (base y avanzada) con comparación antes/después.
4. Detección de outliers (IQR/z-score y Mahalanobis) + evaluación de impacto.
5. Selección preliminar de variables (correlaciones altas + VIF).
6. (Opcional) modelado y evaluación.

Regla de escritura: cada bloque debe cerrar con 3–6 líneas que respondan: *qué observé, por qué importa, y qué haré con eso*.

3.2. Entregable 2: Documento de soporte de decisiones (PDF)

Propósito: Justificar decisiones. Se espera que se vea **claro**:

- Decisión tomada,
- Alternativas consideradas,
- Evidencia (resultado/figura/métrica),
- Criterio y referencias (clase + literatura),
- Impacto/limitación.

Decisión	Evidencia	Criterio/Referencia	Impacto/Riesgo
Imputación (método)	Fig./métrica antes–después	Libro/artículo/doc.	Sesgo/varianza/limitación
Outliers (tratamiento)	Cambios en estadísticos	Criterio (IQR/Mahal.)	Pérdida de info/robustez
Variables finales	VIF, correlación, rendimiento	Literatura + criterio	Interpretabilidad/fuga

Cuadro 1: Plantilla mínima para sustentar decisiones (puede ampliarse).

3.3. Entregable 3: Presentación

Máximo 10–12 diapositivas (recomendado). Debe incluir:

1. Problema y objetivo (1 slide).
2. Datos (1 slide: tamaño, variables, limitaciones).
3. Hallazgos EDA clave (2–3 slides con interpretación).
4. Decisiones técnicas críticas (2 slides: imputación, outliers, variables; con evidencia).
5. (Opcional) resultados de modelado (1–2 slides).
6. Conclusiones y recomendaciones (1 slide).

3.4. Entregable 4: Dashboard

Debe permitir:

- ver indicadores clave y patrones relevantes,
- explorar resultados del EDA (uni/bivariado) con filtros,
- mostrar evidencia del tratamiento de faltantes y outliers (antes vs después),
- documentar variables seleccionadas y justificación resumida,
- incluir filtros/segmentación coherentes con el problema.

4. Estructura del informe final (plantilla)

4.1. Resumen ejecutivo

- ¿Qué problema se abordó y cuál era el objetivo?
- ¿Cuáles son los hallazgos accionables más importantes?
- ¿Qué limitaciones afectan la interpretación o la generalización?

4.2. 1. Contexto, problema y objetivos

- Contexto del dominio (1–2 párrafos).
- Objetivo general y objetivos específicos.
- Definición de variable objetivo (si aplica) y por qué es relevante.

4.3. 2. Datos y diccionario de variables

- Fuente del dataset, licencia (si aplica), fecha de extracción/obtención.
- Diccionario: nombre, tipo, descripción, unidades/rangos esperados.

Variable	Tipo	Descripción	Notas (rango/unidad)
var1	numérica	...	...
var2	categorica	...	...

Cuadro 2: Diccionario de variables.

4.4. 3. Metodología de EDA (obligatoria)

4.4.1. 3.1 Carga y exploración inicial

Tareas mínimas (hacer y reportar):

1. Cargar el dataset y mostrar las primeras 10 filas.
2. Resumen por variable: tipo, # categorías únicas, proporción de nulos.
3. Estadísticas básicas: mínimo, máximo, media, mediana, varianza, desviación estándar.
4. Asimetría y curtosis (variables numéricas).
5. Frecuencias y barras (variables categóricas).
6. Duplicados, inconsistencias, rangos y plausibilidad.

Preguntas de análisis (técnicas):

1. ¿Cuál es el tamaño del dataset (filas/columnas)?
2. ¿Qué tipos predominan?
3. ¿Hay categorías demasiado raras?
4. ¿Qué variables muestran valores fuera de rango?
5. ¿Hay desbalance en la variable objetivo (si existe)?
6. ¿Hay identificadores irrelevantes?

Preguntas de contexto/negocio:

1. ¿Qué problema se puede abordar con este dataset?
2. ¿Qué variables parecen críticas para decisiones?
3. ¿Qué implica que la variable objetivo esté desbalanceada?
4. ¿Qué limitaciones afectan la confiabilidad del dataset?

4.4.2. 3.2 Análisis univariado

Tareas mínimas (hacer y reportar):

1. Histogramas, boxplots y densidades de variables numéricas.
2. Pruebas de normalidad (cuando aplique): Shapiro-Wilk, KS, χ^2 de ajuste.
3. Medidas de dispersión: rango, varianza, IQR.
4. Frecuencias/proporciones (categóricas) y discusión de dominancia de categorías.

Interpretación requerida: sesgo, colas pesadas, diferencias media vs mediana, categorías dominantes, valores sospechosos.

4.4.3. 3.3 Análisis bivariado

Tareas mínimas (hacer y reportar):

1. Correlaciones: Pearson, Spearman, Kendall (según el caso).
2. Heatmap de correlaciones.
3. Pruebas según tipo de variables (cuando aplique): t , z , ANOVA, Kruskal-Wallis, Mann-Whitney, Wilcoxon, χ^2 , Fisher.
4. Visualizaciones: scatterplots y boxplots comparativos (y otros si son pertinentes).
5. Asociación con variable objetivo (si aplica).

Interpretación requerida: relaciones no lineales, variables con relación fuerte, hallazgos inesperados, posibles confusores.

4.4.4. 3.4 Valores faltantes e imputación

Tareas mínimas (hacer y reportar):

1. Cuantificar y visualizar nulos (p.ej. heatmap o matriz de faltantes).
2. Evaluar si los nulos son aleatorios o estructurados.
3. Imputación simple: media/mediana/moda.
4. Imputación avanzada: KNN e iterativa.
5. Comparar distribuciones antes vs después (y, si es posible, correlaciones).

Conclusión requerida: método elegido y justificación (estructura preservada, coherencia con el problema, riesgos).

4.4.5. 3.5 Atípicos (outliers)

Tareas mínimas (hacer y reportar):

1. Detección univariada: IQR y z-scores.
2. Detección multivariada: distancia de Mahalanobis.
3. Clasificar: naturales vs artificiales (errores/artefactos).
4. Evaluar impacto en estadísticos (medias, correlaciones, pruebas).
5. Tratamiento: eliminación, winsorización o imputación; comparar resultados.

Justificación requerida: por qué el tratamiento es coherente con el contexto y con la calidad del dato.

4.4.6. 3.6 Selección preliminar de variables

Tareas mínimas (hacer y reportar):

1. Identificar variables altamente correlacionadas y redundantes.
2. Calcular VIF (multicolinealidad).
3. Proponer un conjunto reducido de variables (y justificar descartes).

4.5. 5. Síntesis y dashboard

El dashboard debe incluir, como mínimo:

- Estadísticas clave.
- Visualizaciones uni/bivariadas relevantes.
- Resultados de imputación (antes vs después).
- Manejo de outliers (impacto y decisión).
- Variables seleccionadas (y por qué).
- Filtros interactivos.

4.6. 6. Conclusiones, limitaciones y recomendaciones

- Hallazgos principales (qué cambia decisiones).
- Limitaciones (datos, sesgos, faltantes, desbalance, medición).
- Recomendaciones accionables y próximos pasos.

4.7. 7. Ética y uso responsable

- ¿Qué sesgos podrían existir?
- ¿Qué decisiones podrían afectar personas/grupos?
- ¿Qué medidas de mitigación proponen?

5. Rúbrica

Criterio	Peso
Problema, objetivos y contexto (claridad y alcance)	10 %
Interpretación en el Notebook (lectura crítica, coherencia, narrativa)	20 %
Documento de decisiones (evidencia + referencias + argumentación)	25 %
Faltantes e imputación (diagnóstico, comparación, decisión sustentada)	15 %
Outliers (detección, impacto, tratamiento justificado)	15 %
Dashboard (síntesis, exploración, claridad, filtros)	10 %
Presentación (estructura, comunicación, conclusiones)	5 %

Cuadro 3: Rúbrica

6. Checklist antes de entregar

- El notebook corre de inicio a fin sin errores y explica *qué/por qué/qué significa*.
- Cada decisión importante aparece en el PDF con evidencia y referencias.
- La presentación resume lo esencial (hallazgos + decisiones + recomendaciones).
- El dashboard permite explorar (filtros) y no solo mostrar.
- Referencias completas (autor, año, título y fuente/enlace cuando aplique).

Sugerencia al estudiante: se espera iniciativa investigativa para complementar vacíos, siempre sustentando decisiones con referencias y resultados.