

Documento de Soporte de Decisiones

Proyecto Final — Data Mining
Análisis de Ventas Globales de Videojuegos (vgsales)

Universidad Externado de Colombia
Departamento de Matemáticas

Mayo de 2026

Nota de autoría. El presente documento corresponde al Entregable 2 del Proyecto Final de la asignatura Data Mining. Su propósito es justificar cada decisión técnica tomada durante el análisis mediante evidencia empírica, alternativas evaluadas y referencias bibliográficas. El dataset empleado es *Video Game Sales*, obtenido de Kaggle (VGChartz, 2016), con 16,598 registros y 11 variables que cubren el periodo 1980–2020.

Resumen

Este documento presenta las decisiones técnicas adoptadas durante el análisis exploratorio de datos del dataset *vgsales*. Se documentan diez decisiones que abarcan la elección de pruebas estadísticas, el tratamiento de valores faltantes, la detección y manejo de valores atípicos, y la selección preliminar de variables. Para cada decisión se especifica la alternativa elegida, las opciones descartadas, la evidencia empírica que respalda la elección, los criterios metodológicos con sus respectivas referencias bibliográficas en formato APA 7.^a edición, y el impacto o limitación asociado. El análisis concluye que las distribuciones de ventas son no normales y fuertemente sesgadas, que la imputación por KNN preserva mejor la estructura de la variable *Year*, que la winsorización es el tratamiento más apropiado para los valores atípicos en este contexto, y que *Global_Sales* debe excluirse como predictor por presentar multicolinealidad perfecta ($VIF = 98,947$) con las variables regionales.

Palabras clave: ventas de videojuegos, imputación KNN, Mahalanobis, winsorización, selección de variables, Kruskal-Wallis, APA.

Introducción

El presente documento tiene como finalidad registrar y justificar las decisiones técnicas adoptadas en el Proyecto Final de Data Mining, cuyo objeto de estudio es el conjunto de datos *Video Game Sales* (VGChartz, 2016). Dicho dataset reúne información de 16,598 videojuegos publicados entre 1980 y 2020, incluyendo variables de ventas por región geográfica (Norteamérica, Europa, Japón y Otras regiones), así como atributos cualitativos como género, plataforma y empresa editora.

La rúbrica del proyecto asigna un 25% de la calificación total a este entregable, lo que refleja la importancia de la trazabilidad y justificación de las decisiones en un análisis riguroso de datos. En consecuencia, cada sección de este documento sigue la estructura propuesta en el enunciado: decisión tomada, alternativas consideradas, evidencia empírica, criterio con referencia bibliográfica e impacto o limitación. Las citas siguen el formato APA 7.^a edición (American Psychological Association, 2020).

Decisión 1. Elección de la prueba de normalidad

Antecedente y decisión

Previo al análisis bivariado era necesario determinar si las cinco variables de ventas (NA_Sales, EU_Sales, JP_Sales, Other_Sales y Global_Sales) siguen una distribución normal, dado que este supuesto condiciona la elección de coeficientes de correlación y pruebas de hipótesis. Se optó por la prueba de Shapiro-Wilk aplicada sobre una submuestra aleatoria de $n = 5,000$ observaciones por variable (semilla aleatoria = 42). El tamaño de la submuestra se justifica porque Shapiro-Wilk pierde sensibilidad diagnóstica con muestras muy grandes, tendiendo a rechazar H_0 ante desviaciones triviales de la normalidad (Razali y Wah, 2011).

Alternativas consideradas

Se evaluaron como alternativas la prueba de Kolmogorov-Smirnov y la inspección visual mediante histogramas y gráficos Q-Q. La prueba de Kolmogorov-Smirnov fue descartada porque, con $n = 16,598$, su elevada potencia estadística detectaría como significativas desviaciones mínimas sin relevancia práctica. La inspección visual fue utilizada como complemento, pero no como criterio formal, dado su carácter subjetivo.

Evidencia empírica

Los resultados de la prueba de Shapiro-Wilk arrojaron estadísticos W entre 0.18 y 0.26 con valores $p = 0.000000$ en todas las variables, lo que lleva a rechazar H_0 de normalidad en todos los casos. Este resultado es consistente con los histogramas, que muestran distribuciones fuertemente sesgadas a la derecha: la media de Global_Sales (0.537 M) supera en más de tres veces a la mediana

(0.170 M), indicando que un pequeño número de títulos concentra la mayoría de las ventas del mercado.

Impacto

La confirmación de no normalidad obliga a utilizar estadísticos no paramétricos en el análisis bivariado: el coeficiente de correlación de Spearman en lugar de Pearson (Decisión 2) y la prueba de Kruskal-Wallis en lugar de ANOVA (Decisión 3). Esta decisión se apoya en Shapiro y Wilk (1965) y en las recomendaciones metodológicas de Razali y Wah (2011) para muestras de tamaño moderado a grande.

Decisión 2. Método de correlación entre variables numéricas

Antecedente y decisión

Para cuantificar la asociación entre las variables de ventas se eligió el coeficiente de correlación de Spearman como medida principal, dado que los datos no cumplen el supuesto de normalidad demostrado en la Decisión 1. El coeficiente de Pearson se calculó como referencia comparativa, pero no se emplea para inferencia estadística.

Evidencia empírica y razonamiento

La diferencia entre ambos coeficientes resulta diagnósticamente relevante. En el par JP_Sales vs. NA_Sales, Pearson reporta $r = 0.45$, mientras que Spearman arroja $\rho = -0.23$: una inversión de signo que Pearson ocultaba por la influencia desproporcionada de los valores extremos. Este hallazgo sugiere que el mercado japonés opera con preferencias opuestas a las del mercado norteamericano en el rango medio de ventas, lo que constituye un insight de negocio relevante que solo emerge con el estadístico adecuado. Entre NA_Sales y Global_Sales, Pearson reporta $r = 0.941$ y Spearman $\rho \approx 0.90$; la ligera diferencia se explica por la menor influencia de los outliers en el rango de Spearman.

La elección se sustenta en Hauke y Kossowski (2011), quienes demuestran que Spearman es preferible cuando los datos presentan distribuciones asimétricas o contienen valores atípicos influyentes, y en Corder y Foreman (2014), que lo señalan como el coeficiente no paramétrico estándar para medición de asociación monotónica.

Decisión 3. Prueba de diferencias entre grupos (Kruskal-Wallis)

Antecedente y decisión

Para determinar si las ventas globales difieren significativamente entre géneros y plataformas se aplicó la prueba de Kruskal-Wallis, alternativa no paramétrica al ANOVA de una vía. Esta elección

es consecuencia directa de la Decisión 1: dado que Global_Sales no sigue una distribución normal y la homogeneidad de varianzas no puede asumirse, el ANOVA clásico no es aplicable (McKight y Najab, 2010).

Evidencia empírica

La prueba arrojó diferencias estadísticamente significativas tanto por género ($H = 970.45$, $p < .001$) como por plataforma en las diez más frecuentes ($H = 1,276.50$, $p < .001$). En términos sustantivos, los géneros Platform y Shooter lideran en mediana de ventas globales, mientras que Adventure y Strategy presentan el rendimiento más bajo. Por plataforma, PS3 y X360 exhiben las medianas más altas, coherente con el auge de la séptima generación de consolas (2005–2012).

Como limitación, la prueba de Kruskal-Wallis solo indica que al menos un grupo difiere, sin identificar cuáles pares son distintos. Un análisis post-hoc con la prueba de Dunn y corrección de Bonferroni permitiría comparaciones múltiples, pero está fuera del alcance del presente análisis.

Decisión 4. Imputación de la variable Year

Antecedente y decisión

La variable Year presenta 271 valores nulos (1.63% del total). El primer paso consistió en diagnosticar el mecanismo de ausencia mediante la comparación de la distribución de Global_Sales entre registros con y sin valor en Year. Los boxplots resultantes mostraron distribuciones similares en ambos grupos, lo que es consistente con un mecanismo MAR (*Missing At Random*): los valores faltantes no parecen relacionados con el nivel de ventas del juego. Bajo este diagnóstico, la imputación está justificada y no introduce sesgo sistemático (Little y Rubin, 2002).

Se eligió el método KNN Imputer con $K = 5$ vecinos más cercanos, aplicado sobre las variables {Year, NA_Sales, EU_Sales, JP_Sales, Other_Sales, Global_Sales} escaladas previamente con RobustScaler. La escala robusta se justifica porque las variables de ventas contienen outliers extremos que distorsionarían el cálculo de distancias en un escalado estándar (Min-Max o Z-score).

Comparación de métodos

Se evaluaron tres alternativas. La imputación por mediana (2007) es sencilla pero genera un pico artificial en ese año al concentrar los 271 registros en un único valor, reduciendo la desviación estándar de 5.83 a 5.78. La imputación iterativa (MICE) ofrece mayor precisión teórica, pero con solo 271 nulos el beneficio marginal no compensa la complejidad computacional adicional. La eliminación de filas representaría una pérdida de 271 observaciones sin justificación suficiente dado el bajo porcentaje de ausencia.

KNN preserva la desviación estándar original (5.83) de forma exacta y distribuye los valores imputados de manera coherente con el contexto de cada juego, tomando como referencia sus ventas regionales para encontrar años similares. Este comportamiento es preferible al de la mediana, según Troyanskaya et al. (2001), quienes demuestran que KNN preserva mejor la estructura de correlación de los datos frente a métodos univariados.

Decisión 5. Imputación de la variable Publisher

Antecedente y decisión

Publisher es una variable categórica con 58 nulos (0.35%) y una cardinalidad de más de 500 editoras distintas. Se optó por imputar con la moda del dataset, que corresponde a Electronic Arts. El mecanismo de ausencia se diagnosticó igualmente como MAR: la distribución de Global_Sales entre registros con y sin Publisher es similar.

La imputación KNN sobre variables categóricas de alta cardinalidad requeriría codificación one-hot, lo que generaría una matriz dispersa de más de 500 columnas adicionales y un costo computacional desproporcionado para apenas 58 registros. Asignar una categoría 'Desconocido' sería semánticamente más honesto, pero introduciría una categoría artificial que distorsionaría los análisis de frecuencia. Dado que los 58 nulos representan menos del 0.5% del total, su impacto en cualquier análisis posterior es mínimo, lo que valida el uso de la moda como solución pragmática (van Buuren, 2018).

Decisión 6. Detección univariada de outliers: IQR y Z-score

Antecedente y decisión

Como primera aproximación al análisis de valores atípicos se aplicaron dos criterios univariados clásicos sobre las cinco variables de ventas. El criterio IQR (umbral $1.5 \times \text{IQR}$, Tukey, 1977) y el Z-score (umbral $|z| > 3$) se emplearon en modo exploratorio, no como criterio definitivo de eliminación.

Evidencia empírica

Variable	Outliers IQR	% IQR	Outliers Z-score	% Z-score
NA_Sales	1,681	10.1%	174	1.0%
EU_Sales	2,081	12.5%	214	1.3%
JP_Sales	2,425	14.6%	238	1.4%
Other_Sales	1,665	10.0%	177	1.1%
Global_Sales	1,893	11.4%	181	1.1%

Nota. IQR con umbral $1.5 \times \text{IQR}$ según Tukey (1977). Z-score con umbral $|z| > 3$.

La discrepancia entre ambos métodos —IQR detecta entre 10% y 15% de outliers mientras que Z-score detecta alrededor del 1%— es una consecuencia directa del fuerte sesgo positivo de las distribuciones. El criterio IQR sobre-detecta valores atípicos en distribuciones asimétricas porque los cuartiles se comprimen hacia cero cuando la mayoría de los juegos venden muy poco. Dado este comportamiento, el criterio IQR se usó únicamente como diagnóstico exploratorio; el tratamiento definitivo se basó en la detección multivariada descrita en la Decisión 7.

Decisión 7. Detección multivariada: distancia de Mahalanobis

Antecedente y decisión

La detección univariada no captura si una observación es atípica en función de la combinación de sus valores en múltiples variables. Un juego puede tener ventas altas en todas las regiones simultáneamente —comportamiento de un blockbuster global— sin ser inusual multivariadamente. Para superar esta limitación se aplicó la distancia de Mahalanobis, que mide cuántas desviaciones estándar multivariadas separa a una observación del centroide del conjunto (Mahalanobis, 1936).

El umbral se fijó en $d_M > \sqrt{(\chi^2_{0.95, gl=5})} = 3.327$, criterio estándar para espacios de cinco dimensiones (Rousseeuw y Van Zomeren, 1990; Tabachnick y Fidell, 2013). Con este umbral se

identificaron 659 observaciones candidatas a outlier multivariado (3.97% del total).

Como métodos alternativos se consideraron Isolation Forest y LOF (Local Outlier Factor). Ambos son más robustos ante la violación del supuesto de normalidad multivariada, pero carecen de umbral estadístico formal y son menos interpretables en el contexto académico del proyecto. La distancia de Mahalanobis fue preferida por su transparencia metodológica y por permitir vincular el umbral directamente con la distribución chi-cuadrado.

Decisión 8. Clasificación de outliers: naturales versus artificiales

Antecedente y decisión

No todo valor atípico corresponde a un error de medición. En el mercado de videojuegos, los títulos de gran éxito —denominados *blockbusters*— generan ventas que son genuinamente extremas respecto al resto del mercado. Eliminarlos sin distinción sesgaría el análisis al descartar información relevante sobre el segmento más rentable de la industria. En línea con la distinción propuesta por Hawkins (1980) entre 'error outliers' y 'interesting outliers', se diseñó una regla de clasificación binaria basada en dos criterios de integridad interna del dataset.

Un outlier se clasifica como **artificial** cuando cumple al menos una de las siguientes condiciones: (a) alguna de sus ventas regionales es negativa, valor que carece de sentido físico en el contexto de unidades vendidas, o (b) el valor absoluto de la diferencia entre Global_Sales y la suma de las cuatro regiones supera 0.01 millones, lo que indica una inconsistencia aritmética que no puede atribuirse al redondeo. Todo outlier que no cumpla ninguna de estas condiciones se clasifica como **natural**.

Aplicada esta regla sobre los 659 outliers detectados, 544 resultaron naturales (82.5%) y 115 artificiales (17.5%). Los casos naturales incluyen títulos como *Wii Sports* ($d_M = 60.47$) y *Super Mario Bros.* ($d_M = 49.68$), cuyas ventas son extremas pero internamente coherentes. Los artificiales presentan inconsistencias entre la suma de regiones y el valor reportado de ventas globales, lo que sugiere errores en la recopilación de datos de VGChartz.

Decisión 9. Tratamiento de outliers: winsorización

Antecedente y decisión

Con 659 outliers identificados —544 naturales y 115 artificiales— se debía decidir un tratamiento coherente con la naturaleza del fenómeno. Los 115 artificiales fueron eliminados directamente por representar errores de datos. Para los 544 naturales se evaluaron tres estrategias: eliminación completa, imputación con mediana y winsorización al 1%-99%.

Comparación de tratamientos

Estadístico	Original	Eliminación	Winsorización	Imputación
Media Global_Sales (M)	0.537	0.353	0.479	0.346
Desv. estándar Global_Sales	1.555	0.511	0.858	0.502
Registros perdidos	0	659	0	0
Reducción en media (%)	—	34.3%	10.8%	35.6%

Nota. Winsorización aplicada con `scipy.stats.mstats.winsorize` al 1% inferior y 1% superior.

La eliminación reduce la media en un 34.3% y descarta información real sobre el segmento premium del mercado. La imputación con mediana produce una reducción similar (35.6%) y comprime artificialmente la varianza. La winsorización, en cambio, preserva la totalidad de las observaciones y reduce la media solo un 10.8%, limitando únicamente la influencia de los valores más extremos sin eliminarlos del análisis.

Esta decisión se apoya en Wilcox (2012), quien señala que la winsorización es el tratamiento preferido cuando se desea reducir la influencia de extremos sin incurrir en pérdida de observaciones, y en Tukey (1977), quien la recomienda frente a la eliminación cuando los outliers son fenómenos reales aunque influyentes. Como limitación, la winsorización subestima las ventas máximas efectivas (e.g., *Wii Sports*: 82.74 M se reduce al percentil 99). Para análisis específicos del segmento de blockbusters se recomienda trabajar con el dataset original sin este tratamiento.

Decisión 10. Selección preliminar de variables: eliminación de Global_Sales

Antecedente y decisión

El dataset incluye cinco variables de ventas, pero Global_Sales es por definición la suma aritmética exacta de las otras cuatro regiones. Incluirla como predictor en cualquier modelo introduce multicolinealidad perfecta, lo que invalida los coeficientes de regresión y hace imposible la

interpretación de efectos individuales (Kutner et al., 2004). En consecuencia, Global_Sales se eliminó del conjunto de predictores, quedando como variable de respuesta potencial en análisis futuros.

Evidencia empírica

Variable	VIF	Correlación con Global_Sales	Decisión
NA_Sales	26,944	$r = 0.941$	Retener
EU_Sales	10,125	$r = 0.903$	Retener
JP_Sales	3,719	$r = 0.612$	Retener
Other_Sales	1,386	$r = 0.748$	Retener
Global_Sales	98,947	—	Eliminar

Nota. VIF calculado con *variance_inflation_factor* de *statsmodels*. Valores VIF > 10 indican multicolinealidad severa (Hair et al., 2019). VIF = 98,947 indica colinealidad casi perfecta.

Un VIF superior a 10 ya constituye una señal de multicolinealidad severa según Hair et al. (2019); el valor de 98,947 de Global_Sales confirma que se trata de una combinación lineal exacta de las demás variables. Los VIF de NA_Sales y EU_Sales también son elevados entre sí (26,944 y 10,125 respectivamente), lo que sugiere que para modelos lineales sería conveniente aplicar reducción de dimensionalidad mediante PCA o regularización Ridge. Para modelos basados en árboles de decisión (Random Forest, XGBoost), la multicolinealidad entre regiones no representa un problema metodológico.

Consideraciones éticas y uso responsable

El dataset *vgsales* no contiene información personal identificable, por lo que no plantea riesgos de privacidad. Sin embargo, existen sesgos estructurales que deben comunicarse con transparencia. En primer lugar, la fuente original (VGChartz) agrupa en la categoría 'Other' todos los mercados fuera de Norteamérica, Europa y Japón, incluyendo Latinoamérica, África y Asia meridional. Cualquier conclusión sobre tendencias globales de la industria debe reconocer esta subrepresentación geográfica.

En segundo lugar, los años posteriores a 2012 están incompletos en el dataset, de modo que la caída observada en el número de títulos publicados tras ese año refleja un déficit de datos y no necesariamente una contracción del mercado. Aplicar el modelo a decisiones sobre la industria actual sin considerar el auge de las ventas digitales (Steam, PlayStation Network, Xbox Live) podría conducir a conclusiones equivocadas. Por tanto, los hallazgos de este análisis tienen validez descriptiva para el periodo 1980–2012 y deben complementarse con fuentes de datos más recientes antes de usarse como base para decisiones de inversión o desarrollo de productos.

Referencias

- American Psychological Association. (2020). *Publication manual of the American Psychological Association* (7.^a ed.). <https://doi.org/10.1037/0000165-000>
- Corder, G. W., y Foreman, D. I. (2014). *Nonparametric statistics for non-statisticians: A step-by-step approach* (2.^a ed.). Wiley.
- Hair, J. F., Black, W. C., Babin, B. J., y Anderson, R. E. (2019). *Multivariate data analysis* (8.^a ed.). Cengage Learning.
- Han, J., Kamber, M., y Pei, J. (2011). *Data mining: Concepts and techniques* (3.^a ed.). Morgan Kaufmann.
- Hauke, J., y Kossowski, T. (2011). Comparison of values of Pearson's and Spearman's correlation coefficients on the same sets of data. *Quaestiones Geographicae*, 30(2), 87–93. <https://doi.org/10.2478/v10117-011-0021-1>
- Hawkins, D. M. (1980). *Identification of outliers*. Chapman and Hall.
- Iglewicz, B., y Hoaglin, D. C. (1993). *How to detect and handle outliers* (Vol. 16). ASQC Quality Press.
- Kruskal, W. H., y Wallis, W. A. (1952). Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association*, 47(260), 583–621. <https://doi.org/10.2307/2280779>
- Kutner, M. H., Nachtsheim, C. J., Neter, J., y Li, W. (2004). *Applied linear statistical models* (5.^a ed.). McGraw-Hill/Irwin.
- Little, R. J. A., y Rubin, D. B. (2002). *Statistical analysis with missing data* (2.^a ed.). Wiley. <https://doi.org/10.1002/9781119013563>
- Mahalanobis, P. C. (1936). On the generalized distance in statistics. *Proceedings of the National Institute of Sciences of India*, 2(1), 49–55.
- McKight, P. E., y Najab, J. (2010). Kruskal-Wallis test. En I. B. Weiner y W. E. Craighead (Eds.), *The Corsini encyclopedia of psychology* (4.^a ed., pp. 1–1). Wiley.
- Razali, N. M., y Wah, Y. B. (2011). Power comparisons of Shapiro-Wilk, Kolmogorov-Smirnov, Lilliefors and Anderson-Darling tests. *Journal of Statistical Modeling and Analytics*, 2(1), 21–33.
- Rousseeuw, P. J., y Van Zomeren, B. C. (1990). Unmasking multivariate outliers and leverage points. *Journal of the American Statistical Association*, 85(411), 633–639.

<https://doi.org/10.2307/2289995>

Shapiro, S. S., y Wilk, M. B. (1965). An analysis of variance test for normality (complete samples). *Biometrika*, 52(3–4), 591–611. <https://doi.org/10.2307/2333709>

Scikit-learn developers. (2024). *sklearn.impute.KNNImputer*. Scikit-learn. <https://scikit-learn.org/stable/modules/generated/sklearn.impute.KNNImputer.html>

Tabachnick, B. G., y Fidell, L. S. (2013). *Using multivariate statistics* (6.^a ed.). Pearson.

Troyanskaya, O., Cantor, M., Sherlock, G., Brown, P., Hastie, T., Tibshirani, R., Botstein, D., y Altman, R. B. (2001). Missing value estimation methods for DNA microarrays. *Bioinformatics*, 17(6), 520–525. <https://doi.org/10.1093/bioinformatics/17.6.520>

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

van Buuren, S. (2018). *Flexible imputation of missing data* (2.^a ed.). CRC Press. <https://stefvanbuuren.name/fimd/>

VGChartz. (2016). *Video game sales* [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/regorut/videogamesales>

Wilcox, R. R. (2012). *Introduction to robust estimation and hypothesis testing* (3.^a ed.). Academic Press.