

Documento de Soporte de Decisiones

Proyecto Final — Data Mining
Análisis de Ventas Globales de Videojuegos (vgsales)

Universidad Externado de Colombia
Departamento de Matemáticas

Mayo de 2026

Nota de autoría. El presente documento justifica cada decisión técnica adoptada durante el análisis exploratorio de datos del Proyecto Final de Data Mining. El dataset empleado es *Video Game Sales* (VGChartz, 2016), con 16,598 registros y 11 variables que cubren el periodo 1980–2020. Las citas siguen el formato APA 7.^a edición.

Resumen

Este documento presenta doce decisiones técnicas adoptadas durante el análisis exploratorio del dataset *vgsales*. La versión final del notebook incorpora pruebas de normalidad adicionales (Kolmogorov-Smirnov y Chi-cuadrado), la correlación de Kendall como tercer coeficiente, las pruebas de Mann-Whitney U y Chi-cuadrado de independencia entre categóricas, la imputación iterativa (MICE) como alternativa evaluada frente a KNN, y la verificación explícita de la reducción del VIF al eliminar *Global_Sales*. Para cada decisión se documentan la alternativa elegida, las opciones descartadas, la evidencia empírica, los criterios con sus referencias bibliográficas en APA 7.^a edición, y el impacto o limitación asociado.

Palabras clave: ventas de videojuegos, normalidad, Shapiro-Wilk, KS, Kendall, Mann-Whitney, Chi-cuadrado, imputación KNN, MICE, Mahalanobis, winsorización, VIF.

Introducción

El presente documento registra y justifica las decisiones técnicas adoptadas en el Proyecto Final de Data Mining, cuyo objeto de estudio es el conjunto de datos *Video Game Sales* (VGChartz, 2016). La versión definitiva del notebook fue enriquecida con pruebas estadísticas adicionales respecto a la versión inicial: se incorporaron Kolmogorov-Smirnov y Chi-cuadrado de ajuste para reforzar el diagnóstico de normalidad; la correlación de Kendall como tercer coeficiente comparativo; la prueba de Mann-Whitney U para comparaciones por pares entre grupos; la prueba Chi-cuadrado de independencia entre variables categóricas; la imputación iterativa MICE como alternativa formal a KNN; y la tabla de VIF antes y después de eliminar Global_Sales. Cada una de estas adiciones modifica o enriquece las decisiones documentadas y se refleja en las secciones correspondientes de este documento.

Decisión 1. Elección de las pruebas de normalidad

Antecedente y decisión

Para determinar si las variables de ventas siguen una distribución normal se aplicaron tres pruebas complementarias: Shapiro-Wilk sobre una submuestra de $n = 5,000$ observaciones (semilla = 42), Kolmogorov-Smirnov (KS) sobre el dataset completo, y Chi-cuadrado de ajuste con 20 intervalos de clase. El uso de tres pruebas independientes refuerza la solidez del diagnóstico: si todas convergen en el mismo resultado, la conclusión es más robusta que si se apoyara en un único estadístico (Razali y Wah, 2011).

Evidencia empírica

Variable	W (Shapiro)	p (Shapiro)	p (KS)	p (χ^2)	Normal?
NA_Sales	0.2318	0.000000	0.000000	0.000000	No
EU_Sales	0.2030	0.000000	0.000000	0.000000	No
JP_Sales	0.2583	0.000000	0.000000	0.000000	No
Other_Sales	0.1764	0.000000	0.000000	0.000000	No
Global_Sales	0.2252	0.000000	0.000000	0.000000	No

Nota. Shapiro-Wilk: $n=5,000$, random_state=42. KS: muestra completa. χ^2 : 20 bins.

Los tres tests rechazan H_0 de normalidad con $p = 0.000$ en todas las variables. La triangulación de pruebas es especialmente importante porque KS con $n = 16,598$ tiene potencia muy alta y detecta desviaciones mínimas; su coincidencia con Shapiro-Wilk y Chi-cuadrado descarta que el rechazo sea un artefacto del tamaño muestral. La asimetría positiva supera 3 en todas las variables de ventas y la

curtosis es leptocúrtica, coherente con una distribución tipo ley de potencia.

Este diagnóstico obliga a emplear estadísticos no paramétricos en todo el análisis bivariado: Spearman y Kendall para correlaciones (Decisión 2), Kruskal-Wallis y Mann-Whitney para comparación de grupos (Decisión 3), y determina la elección de RobustScaler previo a la imputación KNN (Decisión 4).

Decisión 2. Método de correlación: Spearman como medida principal

Antecedente y decisión

Se calcularon los tres coeficientes clásicos de correlación: Pearson, Spearman y Kendall. Dado que los datos no son normales (Decisión 1), Pearson se emplea únicamente como referencia visual. Spearman se adopta como medida principal por su robustez ante distribuciones asimétricas y valores atípicos. Kendall, que es teóricamente más conservador que Spearman ($\tau \approx 2/3 \times \rho$), se usa como verificación: si ambos coinciden en signo y orden relativo, la conclusión es sólida (Hauke y Kossowski, 2011).

Evidencia empírica

Par de variables	Pearson	Spearman	Kendall	Interpretación
NA_Sales – Global_Sales	0.941	~0.90	~0.76	Muy alta, coherente en los 3
EU_Sales – Global_Sales	0.903	~0.87	~0.71	Muy alta, coherente en los 3
JP_Sales – NA_Sales	0.450	–0.23	~–0.15	Signo opuesto: Pearson engañoso

El caso diagnóstico más relevante es JP_Sales vs. NA_Sales: Pearson reporta $r = 0.45$ (correlación positiva moderada), mientras Spearman da $\rho = -0.23$ y Kendall confirma el signo negativo. La divergencia se explica porque Pearson es distorsionado por los blockbusters que venden bien en ambas regiones simultáneamente, enmascarando el patrón de rango inverso que Spearman y Kendall revelan. Kendall, al ser más conservador en magnitud pero igual en signo, valida la conclusión de Spearman.

Decisión 3. Pruebas de diferencias entre grupos: Kruskal-Wallis, Mann-Whitney y Chi-cuadrado

Antecedente y decisión

El análisis bivariado entre variables numéricas y categóricas requirió tres pruebas no paramétricas complementarias. Kruskal-Wallis para comparar $K > 2$ grupos independientes (todos los géneros y plataformas simultáneamente). Mann-Whitney U para la comparación por pares entre el

género de mayor y menor mediana de ventas, y entre NA_Sales y JP_Sales. Chi-cuadrado de independencia para evaluar si las variables categóricas (Género, Plataforma, Publisher) están asociadas entre sí.

Evidencia empírica

Prueba	Comparación	Estadístico	p-valor	Conclusión
Kruskal-Wallis	Global_Sales por Género	H = 970.45	< 0.001	Diferencias significativas
Kruskal-Wallis	Global_Sales por Plataforma	H = 1,276.50	< 0.001	Diferencias significativas
Mann-Whitney U	Género top vs. bottom	Significativo	< 0.001	Diferencia confirmada por pares
Mann-Whitney U	NA_Sales vs. JP_Sales	Significativo	< 0.001	Mercados distintos
Chi-cuadrado	Género × Plataforma	Grande	< 0.001	No independientes
Chi-cuadrado	Género × Publisher	Grande	< 0.001	No independientes
Chi-cuadrado	Plataforma × Publisher	Grande	< 0.001	No independientes

Mann-Whitney complementa a Kruskal-Wallis identificando que el par específico de géneros extremos (mayor vs. menor mediana) difiere significativamente, lo que confirma que el resultado global no es impulsado por un único par de grupos. La prueba Chi-cuadrado entre categóricas revela que Género, Plataforma y Publisher están estructuralmente asociados: algunas plataformas son exclusivas de ciertos publishers (Nintendo/Wii, Sony/PS), y ciertos géneros dominan plataformas específicas (RPG en consolas japonesas). Este hallazgo implica que estas variables no son independientes y deben tratarse con cuidado en modelos que asuman separabilidad de efectos.

Decisión 4. Imputación de Year: KNN frente a mediana, media e imputación iterativa

Antecedente y decisión

Year presenta 271 valores nulos (1.63%). El mecanismo de ausencia se diagnosticó como MAR (*Missing At Random*) mediante la comparación de distribuciones de Global_Sales entre registros con y sin año. Se evaluaron cuatro métodos: mediana, media, KNN ($K = 5$) e imputación iterativa MICE (*IterativeImputer*, $\text{max_iter} = 10$). En todos los casos se aplicó *RobustScaler* previo a los métodos que operan sobre escala, dado que las ventas contienen outliers extremos que distorsionan el escalado estándar.

Comparación de los cuatro métodos

Estadístico	Original	Mediana	Media	KNN	MICE
Media Year	2006.4	2006.8	2006.4	2006.5	~2006.4
Desv. estándar	5.83	5.78	5.78	5.83	5.83
Pico artificial	—	Sí (2007)	Sí (2006)	No	No
Δ correlaciones	—	Leve	Leve	< 0.01	< 0.01

Nota. Δ correlaciones = diferencia máxima en Spearman entre variables de ventas antes y después de imputar.

Mediana y media generan un pico artificial en el histograma (271 juegos concentrados en un único año) y reducen la desviación estándar de 5.83 a 5.78. KNN y MICE preservan ambas métricas con precisión, y los heatmaps de diferencias de correlaciones muestran $\Delta < 0.01$ en todos los pares, confirmando que ninguno de los dos métodos avanzados distorsiona la estructura de asociación del dataset.

Se elige KNN ($K = 5$) sobre MICE porque: (1) con solo 271 nulos (1.63%), la diferencia práctica entre ambos métodos es mínima; (2) KNN es computacionalmente más eficiente para este tamaño de dataset; y (3) las métricas estadísticas son equivalentes. Esta decisión se apoya en Troyanskaya et al. (2001) y van Buuren (2018), quien señala que con baja proporción de nulos bajo MAR, métodos simples bien implementados son suficientes.

Decisión 5. Imputación de Publisher: moda

Publisher presenta 58 nulos (0.35%) y alta cardinalidad (> 500 categorías). El mecanismo MAR fue verificado por comparación de distribuciones. La imputación con la moda (Electronic Arts) introduce un sesgo mínimo: 58 registros adicionales sobre una base de más de 1,000 títulos de EA no

alteran los análisis de frecuencia. KNN sobre variables categóricas de alta cardinalidad requeriría codificación one-hot con > 500 columnas adicionales, un costo computacional injustificado para < 0.5% de nulos. La decisión se sustenta en Little y Rubin (2002) y van Buuren (2018).

Decisión 6. Detección univariada: IQR y Z-score como herramienta exploratoria

Se aplicaron IQR (umbral $1.5 \times \text{IQR}$, Tukey, 1977) y Z-score ($|z| > 3$) sobre las cinco variables de ventas en modo exploratorio, no como criterio definitivo de eliminación. IQR detectó entre 10% y 14.6% de outliers, mientras Z-score detectó alrededor del 1%. La discrepancia es consecuencia del fuerte sesgo positivo: cuando el 75% de valores está comprimido cerca de cero, el IQR es muy pequeño y clasifica como atípico cualquier juego con ventas moderadas. El criterio definitivo de tratamiento se basa en la detección multivariada (Decisión 7).

Decisión 7. Detección multivariada: distancia de Mahalanobis

La distancia de Mahalanobis mide cuántas desviaciones estándar multivariadas separa a una observación del centroide del conjunto, considerando la estructura de covarianza entre las cinco variables de ventas. El umbral se fijó en $d_M > \sqrt{\chi^2_{0.99, 5}} = 3.327$, criterio estándar para espacios de cinco dimensiones (Rousseeuw y Van Zomeren, 1990; Tabachnick y Fidell, 2013). Se identificaron 659 outliers multivariados (3.97%). Isolation Forest y LOF fueron descartados por carecer de umbral estadístico formal y ser menos interpretables en contexto académico.

Decisión 8. Clasificación: outliers naturales versus artificiales

En línea con Hawkins (1980), se distinguieron outliers legítimos de errores de datos. Un outlier se clasifica como **artificial** si: (a) alguna venta regional es negativa, o (b) $|\text{Global_Sales} - (\text{NA} + \text{EU} + \text{JP} + \text{Other})| > 0.01 \text{ M}$, lo que indica inconsistencia aritmética. El resultado sobre los 659 outliers fue 544 naturales (82.5%) y 115 artificiales (17.5%). Los naturales incluyen blockbusters como *Wii Sports* ($d_M = 60.47$) con datos internamente coherentes. Los artificiales presentan discrepancias en la suma de regiones, atribuibles a errores de VGChartz.

Decisión 9. Tratamiento de outliers: winsorización al 1%

Comparación de tratamientos

Estadístico	Original	Eliminación	Winsorización	Imputación
Media Global_Sales (M)	0.537	0.353	0.479	0.346
Desv. estándar	1.555	0.511	0.858	0.502
Registros perdidos	0	659	0	0
Reducción en media (%)	—	34.3%	10.8%	35.6%

Nota. Winsorización al 1% inferior y 1% superior con `scipy.stats.mstats.winsorize`.

Los 115 artificiales se eliminan directamente por representar errores de datos. Para los 544 naturales se elige winsorización: preserva todos los registros, reduce la media solo un 10.8% y mantiene la variabilidad del mercado. La eliminación descartaría los juegos más exitosos de la historia, sesgando cualquier análisis del segmento premium. El notebook señala además que para modelos basados en árboles (Random Forest, XGBoost) los outliers naturales pueden mantenerse sin tratamiento, pues estos algoritmos son robustos a valores extremos (Breiman, 2001). La winsorización se aplica para análisis descriptivos y modelos sensibles a escala. El sustento bibliográfico es Wilcox (2012) y Tukey (1977).

Decisión 10. Selección de variables: eliminación de Global_Sales

Evidencia — VIF con y sin Global_Sales

Variable	VIF (con Global_Sales)	VIF (sin Global_Sales)	Decisión
NA_Sales	26,944	< 10*	Retener
EU_Sales	10,125	< 10*	Retener
JP_Sales	3,719	< 10*	Retener
Other_Sales	1,386	< 10*	Retener
Global_Sales	98,947	—	Eliminar

*Nota. * Al excluir Global_Sales los VIF de las variables regionales caen a niveles manejables según Hair et al. (2019). El notebook verifica explícitamente esta reducción.*

Global_Sales es por definición la suma aritmética exacta de las cuatro regiones. Su VIF de 98,947 confirma redundancia matemática perfecta, no solo correlación alta. El notebook agrega en la versión final la verificación explícita de que al eliminar Global_Sales los VIF de las regionales caen

drásticamente, lo que valida que el conjunto {NA_Sales, EU_Sales, JP_Sales, Other_Sales} es utilizable para modelado lineal. Para modelos de árbol la multicolinealidad entre regiones no es problemática, pero mantener Global_Sales seguiría siendo redundante.

Consideraciones éticas y uso responsable

El dataset no contiene información personal identificable. Sin embargo, presenta dos sesgos estructurales que deben comunicarse con transparencia. Primero, VGChartz agrupa en 'Other' todos los mercados fuera de Norteamérica, Europa y Japón, subrepresentando Latinoamérica, África y Asia meridional. Segundo, los datos posteriores a 2012 están incompletos, de modo que la caída aparente en publicaciones tras ese año refleja un déficit de cobertura y no una contracción real del mercado. Cualquier recomendación de negocio derivada de este análisis debe reconocer estas limitaciones y complementarse con fuentes de ventas digitales (Steam, PSN, Xbox Live) para representar el mercado contemporáneo.

Referencias

- American Psychological Association. (2020). *Publication manual of the American Psychological Association* (7.^a ed.). <https://doi.org/10.1037/0000165-000>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Corder, G. W., y Foreman, D. I. (2014). *Nonparametric statistics for non-statisticians: A step-by-step approach* (2.^a ed.). Wiley.
- Hair, J. F., Black, W. C., Babin, B. J., y Anderson, R. E. (2019). *Multivariate data analysis* (8.^a ed.). Cengage Learning.
- Han, J., Kamber, M., y Pei, J. (2011). *Data mining: Concepts and techniques* (3.^a ed.). Morgan Kaufmann.
- Hauke, J., y Kossowski, T. (2011). Comparison of values of Pearson's and Spearman's correlation coefficients on the same sets of data. *Quaestiones Geographicae*, 30(2), 87–93. <https://doi.org/10.2478/v10117-011-0021-1>
- Hawkins, D. M. (1980). *Identification of outliers*. Chapman and Hall.
- Kruskal, W. H., y Wallis, W. A. (1952). Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association*, 47(260), 583–621. <https://doi.org/10.2307/2280779>
- Kutner, M. H., Nachtsheim, C. J., Neter, J., y Li, W. (2004). *Applied linear statistical models* (5.^a ed.). McGraw-Hill/Irwin.
- Little, R. J. A., y Rubin, D. B. (2002). *Statistical analysis with missing data* (2.^a ed.). Wiley.
- Mahalanobis, P. C. (1936). On the generalized distance in statistics. *Proceedings of the National Institute of Sciences of India*, 2(1), 49–55.
- Mann, H. B., y Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, 18(1), 50–60.
- Razali, N. M., y Wah, Y. B. (2011). Power comparisons of Shapiro-Wilk, Kolmogorov-Smirnov, Lilliefors and Anderson-Darling tests. *Journal of Statistical Modeling and Analytics*, 2(1), 21–33.
- Rousseeuw, P. J., y Van Zomeren, B. C. (1990). Unmasking multivariate outliers and leverage points. *Journal of the American Statistical Association*, 85(411), 633–639.

- Scikit-learn developers. (2024). *sklearn.impute.KNNImputer / IterativeImputer*.
<https://scikit-learn.org/stable/modules/impute.html>
- Shapiro, S. S., y Wilk, M. B. (1965). An analysis of variance test for normality (complete samples).
Biometrika, 52(3–4), 591–611.
- Tabachnick, B. G., y Fidell, L. S. (2013). *Using multivariate statistics* (6.^a ed.). Pearson.
- Troyanskaya, O., et al. (2001). Missing value estimation methods for DNA microarrays.
Bioinformatics, 17(6), 520–525.
- Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.
- van Buuren, S. (2018). *Flexible imputation of missing data* (2.^a ed.). CRC Press.
<https://stefvanbuuren.name/fimd/>
- VGChartz. (2016). *Video game sales* [Conjunto de datos]. Kaggle.
<https://www.kaggle.com/datasets/regorut/videogamesales>
- Wilcox, R. R. (2012). *Introduction to robust estimation and hypothesis testing* (3.^a ed.). Academic Press.