

# Proyecto data mining

Gabriela Aguirre, Jacobo Beltran, Erick Diaz, Daniel Sierra.

2026

# Tabla de contenidos

- 1 Pregunta de investigación
- 2 Contexto del problema
- 3 Objetivos del proyecto
- 4 Diccionario de variables
- 5 Diccionario variables 2
- 6 Tabla de decisiones metodológicas

# Pregunta de investigación

¿Qué factores influyen en el éxito comercial de un videojuego a nivel global?

# Contexto del problema

La industria de los videojuegos es uno de los sectores de entretenimiento con mayor crecimiento a nivel mundial. Cada año se lanzan cientos de videojuegos en diferentes plataformas y géneros, pero solo algunos logran alcanzar un alto nivel de ventas y éxito comercial.

Comprender qué factores influyen en el éxito de un videojuego resulta relevante tanto para desarrolladores como para empresas del sector, ya que permite identificar patrones de consumo, preferencias de los jugadores y características asociadas con mayores niveles de ventas.

En este proyecto se analizará un dataset de ventas de videojuegos que incluye información sobre plataforma, género, año de lanzamiento, empresa publicadora y ventas en diferentes regiones del mundo. A partir de este análisis se busca identificar qué variables están más relacionadas con el éxito comercial de un videojuego, medido a través de las ventas globales.

# Objetivos del proyecto

**Objetivo general:** Analizar los factores que influyen en el éxito comercial de los videojuegos utilizando información de ventas globales, con el fin de identificar patrones asociados a mayores niveles de ventas.

## Objetivos específicos:

- 1 Explorar las características principales del dataset y evaluar la calidad de los datos.
- 2 Analizar la relación entre variables como género, plataforma, año de lanzamiento y ventas por región.
- 3 Identificar posibles problemas en los datos como valores faltantes o valores atípicos.
- 4 Justificar las decisiones metodológicas tomadas durante el proceso de análisis de datos.

# Diccionario de variables

| Variable  | Tipo       | Descripción                                        |
|-----------|------------|----------------------------------------------------|
| Rank      | Numérica   | Ranking del videojuego según ventas globales.      |
| Name      | Categórica | Nombre de videojuego.                              |
| Platform  | Categórica | Plataforma o consola donde se lanzó el videojuego. |
| Year      | Númerica   | Año de lanzamiento del videojuego.                 |
| Genre     | Categórica | Género del videojuego.                             |
| Publisher | Categórica | Empresa publicadora del videojuego.                |

# Diccionario variables 2

| Variable     | Tipo     | Descripción                                    |
|--------------|----------|------------------------------------------------|
| NA sales     | Númerica | Ventas en Norteamérica (millones de unidades). |
| EU sales     | Númerica | Ventas en Europa (millones de unidades).       |
| JP sales     | Númerica | Ventas en Japon (millones de unidades).        |
| Other sales  | Númerica | Ventas en otras regiones del mundo.            |
| Global sales | Númerica | Ventas totales globales del videojuego.        |

# Tabla de decisiones metodológicas

| Decisión                                | Evidencia                                                     | Criterio                                                      | Impacto/Riesgo                                              |
|-----------------------------------------|---------------------------------------------------------------|---------------------------------------------------------------|-------------------------------------------------------------|
| Imputación de valores faltantes en Year | Presencia de valores nulos en la variable año                 | Uso de mediana para evitar distorsión por valores extremos    | Uso de mediana para evitar distorsión por valores extremos  |
| Tratamiento de outliers en ventas       | Boxplots y análisis IQR muestran valores extremadamente altos | Mantener outliers porque representan videojuegos muy exitosos | Evita eliminar casos reales que explican el éxito comercial |
| Selección de variable objetivo          | Interés del análisis en medir el éxito comercial              | Uso de Global_Sales como indicador principal de éxito         | Permite analizar qué factores influyen en mayores ventas    |
| Selección de variables relevantes       | Correlaciones entre ventas regionales y globales              | Evaluación de redundancia y multicolinealidad                 | Mejora interpretabilidad y claridad del análisis            |
| Spearman sobre Pearson                  | Shapiro-wilk $p=0.000$ en todas las variables                 | Datos no normales                                             | Correlaciones mas confiables.                               |
| KNN sobre mediana para Year             | Pico artificial en 2007, $std=5.83$ se preserva con KNN       | Preserva distribución original                                | Costo computacional mayor                                   |