

DATA MINING · 2026

Análisis de Ventas de Videojuegos

Gabriela Aguirre, Jacobo Beltran, Erick Diaz, Daniel Sierra

Pregunta de investigación

¿Qué factores influyen en el éxito comercial de un videojuego a nivel global?

Objetivos del proyecto

Objetivo general: Analizar los factores que influyen en el éxito comercial de los videojuegos utilizando información de ventas globales, con el fin de identificar patrones asociados a mayores niveles de ventas.

Objetivos específicos:

1. Explorar las características principales del dataset y evaluar la calidad de los datos.
2. Analizar la relación entre variables como género, plataforma, año de lanzamiento y ventas por región.
3. Identificar posibles problemas en los datos como valores faltantes o valores atípicos.
4. Justificar las decisiones metodológicas tomadas durante el proceso de análisis de datos.




El Dataset

Registros	16,598
Variables	11
Período	1980–2020
Tipos	4 categ. / 7 numér.



▷ Valores nulos: Year (271, 1.6 %)
y Publisher (58, 0.3 %)

Variable	Tipo	Descripción
Name / Genre	Categ.	Identificadores del juego
Platform / Publisher	Categ.	Identificadores del juego
NA / EU / JP / Other	Numér.	Ventas regionales (M)
Global_Sales	Numér.	Ventas globales (M)
Year	Numér.	Año de lanzamiento


EDA · Distribución de Ventas por Región



EDA · Distribución de Ventas por Región




EDA · Distribución por género




Action domina con más de 3,000 juegos, seguido de Sports y Misc. Los géneros menos representados son Puzzle y Strategy.

EDA · Distribución por género



DS y PS2 concentran la mayor cantidad de títulos, reflejando su popularidad en la era de mayor producción de videojuegos (2000-2010).

EDA · Distribución por género



DS y PS2 concentran la mayor cantidad de títulos, reflejando su popularidad en la era de mayor producción de videojuegos (2000-2010).

Boxplots por región

Los boxplots confirman el sesgo detectado en los histogramas previos. En todas las regiones la caja se comprime cerca de cero: el 75 % de los juegos vende menos de 0.5 M unidades, mientras unos pocos títulos *blockbuster* generan los outliers superiores visibles.

Boxplots sin valores extremos (zoom al P95)

Al recortar el eje al percentil 95, la estructura del mercado se aprecia con mayor claridad. NA_Sales domina en volumen; JP_Sales presenta la distribución más comprimida, reflejando las preferencias distintas del mercado japonés respecto al occidental.

Curvas de densidad (KDE)

Las curvas KDE muestran distribuciones fuertemente unimodales con pico en valores muy bajos y cola derecha extensa. La brecha entre media y mediana —visible en todas las regiones— es arrastrada hacia arriba por los títulos *blockbuster*.

JP_Sales presenta una densidad particularmente comprimida cerca de cero, con una segunda acumulación ligera que sugiere que muchos juegos tienen ventas nulas fuera de Japón.

Pruebas de normalidad

Tres pruebas independientes convergen en el mismo diagnóstico: ninguna variable de ventas sigue una distribución normal.

Variable	Shapiro-Wilk	K-S	Chi ²	Normal?
NA_Sales	$p \ll 0,05$	$p \ll 0,05$	$p \ll 0,05$	No
EU_Sales	$p \ll 0,05$	$p \ll 0,05$	$p \ll 0,05$	No
JP_Sales	$p \ll 0,05$	$p \ll 0,05$	$p \ll 0,05$	No
Other_Sales	$p \ll 0,05$	$p \ll 0,05$	$p \ll 0,05$	No
Global_Sales	$p \ll 0,05$	$p \ll 0,05$	$p \ll 0,05$	No

Esto justifica el uso de pruebas **no paramétricas** en el análisis bivariado: Spearman, Kruskal-Wallis y Mann-Whitney en lugar de Pearson o ANOVA.

Correlaciones entre regiones

NA_Sales y EU_Sales presentan correlación muy alta con Global_Sales ($\rho \approx 0,94$ y $0,90$ en Pearson), dado que son las regiones dominantes. JP_Sales muestra correlaciones más bajas e incluso negativa con NA_Sales en Spearman ($\rho = -0,23$), lo que confirma que el mercado japonés opera con preferencias independientes.

Ventas globales por género y plataforma

Por género, *Platform* y *Shooter* lideran en ventas medianas; *Adventure* y *Strategy* tienen el menor rendimiento. Por plataforma, PS3 y X360 presentan las medianas más altas, reflejando la era dorada de los videojuegos (2005–2012). Wii concentra los outliers más extremos gracias a títulos como *Wii Sports*.

Pruebas estadísticas bivariadas

Kruskal-Wallis

Confirma diferencias significativas en Global_Sales tanto por género como por plataforma ($p < 0,05$ en ambos casos). El género y la plataforma son variables relevantes para explicar las ventas.

Grupo	Estadístico	p -valor
Por Género	alto	$< 0,001$
Por Plataforma	alto	$< 0,001$

El Chi-cuadrado rechaza la independencia entre Genre, Platform y Publisher ($p < 0,05$), lo esperado dado que algunas plataformas son exclusivas de ciertos publishers.

Mann-Whitney U

La diferencia entre el género con mayor y menor mediana de ventas es estadísticamente significativa. De igual forma, NA_Sales y JP_Sales difieren en su distribución central, consistente con la baja correlación de Spearman observada.

Comparación	p -valor
Top vs. Bottom género	$< 0,001$
NA_Sales vs. JP_Sales	$< 0,001$

Diagnóstico de nulos

Solo dos variables presentan valores faltantes: Year (271 nulos, 1.6 %) y Publisher (58 nulos, 0.3 %). Las distribuciones de ventas entre registros con y sin nulos son similares, lo que sugiere un mecanismo **MAR** (*Missing At Random*). Esto valida la imputación sin riesgo de introducir sesgo sistemático.

Comparación de métodos de imputación

La imputación con mediana genera un pico artificial en $\text{Year} = 2007$, concentrando 271 registros en ese año. KNN, en cambio, preserva la desviación estándar original (5.83) y distribuye los valores imputados de forma natural sin generar distorsiones visibles.

Decisión final de imputación

Year → KNN ($k = 5$)

- Preserva la desviación estándar original
- No genera picos artificiales
- Respeta el contexto de cada juego (plataforma, ventas)
- Se aplicó RobustScaler previo al KNN por la presencia de outliers

Publisher → Moda

- Solo 58 nulos (0.3 %) — impacto mínimo
- Nulos distribuidos aleatoriamente (MAR)
- Variable categórica; KNN no aplica directamente

	Orig.	Mediana	KNN
Media	2004.2	2004.4	2004.2
Std	5.83	5.78	5.83

Detección univariada y multivariada

Métodos univariados

Variable	IQR	Z-score
NA_Sales	~14 %	~2 %
EU_Sales	~13 %	~2 %
JP_Sales	~12 %	~1 %
Other_Sales	~13 %	~2 %
Global_Sales	~12 %	~2 %

Distancia de Mahalanobis

Se usó el umbral al percentil 95 de la distribución χ^2 con 5 grados de libertad. Los outliers multivariados capturan combinaciones inusuales entre regiones que los métodos univariados no detectan por separado.

Los outliers se clasificaron en:

- **Naturales:** juegos legítimos de alto impacto (Wii Sports, GTA V. . .)
- **Artificiales:** registros donde la suma de regionales no coincide con Global_Sales

Impacto en estadísticos y decisión final

Al comparar los tres tratamientos, la eliminación reduce la media de Global_Sales en un 34 % y la desviación estándar en un 67 %, descartando información valiosa. La imputación por mediana tiene un efecto similar sin perder filas. Se recomienda **winsorización al 1 %** para modelos sensibles a escala. Los 115 outliers artificiales deben corregirse en cualquier escenario.

Redundancia de Global_Sales y VIF

Global_Sales es, por definición del dataset, la suma exacta de las cuatro regiones. Incluirla como predictor junto a las regionales introduce colinealidad perfecta.

Variable	VIF con Global	VIF sin Global
NA_Sales	26,944	4.1
EU_Sales	14,320	3.8
JP_Sales	3,810	1.5
Other_Sales	8,200	2.9
Global_Sales	99,000	—

Al excluir Global_Sales los VIF caen a niveles manejables (todos < 10 , umbral estándar de Hair et al., 2010).

El conjunto final [NA, EU, JP, Other] representa la variabilidad de ventas sin redundancia estructural.

Resumen del análisis

Hallazgos principales

- Distribución de ventas con alta asimetría positiva en todas las regiones — dominada por unos pocos blockbusters.
- JP_Sales opera de forma independiente al resto del mercado (correlación de Spearman negativa con NA).
- Genre y Platform explican diferencias significativas en ventas (Kruskal-Wallis, $p < 0,001$).
- KNN preserva mejor la distribución

Decisiones metodológicas

- Pruebas no paramétricas por ausencia de normalidad.
- KNN ($k = 5$) + RobustScaler para imputar Year.
- Winsorización al 1 % para outliers naturales.
- Exclusión de Global_Sales como predictor ($VIF \approx 99,000$).

Conclusiones

1. El género del videojuego influye significativamente en su rendimiento comercial. Los géneros Action, Shooter y Sports presentan mayores niveles de ventas que otros géneros.
2. La plataforma de lanzamiento también es un factor clave. Consolas como PS3, Xbox 360 y Wii concentraron los videojuegos más exitosos del análisis.
3. La industria presenta una distribución desigual de ventas: pocos videojuegos concentran gran parte del éxito comercial global.
4. Los videojuegos extremadamente exitosos (“blockbusters”) son fundamentales para entender el comportamiento real del mercado y no deben considerarse anomalías estadísticas.
5. El análisis estadístico confirmó que las diferencias entre géneros y plataformas son significativas, lo que demuestra que las decisiones de diseño y distribución impactan directamente en el éxito de un videojuego.